

The Constant Gardener

GUILHERME CARREIRO GOMES (180074)*, LUÍSA MADEIRA CARDOSO (092109)*, MATEUS CORADINI SANTOS (1595)

*Aluno especial - Mestrado

E-mails: karreiro@gmail.com, lu.madeira2@gmail.com, mateuscoradini@gmail.com

Resumo – O objetivo deste trabalho é implementar um sistema de localização e planejamento de rotas para um robô móvel. Para localização, utilizou-se o filtro Kalman estendido, combinando a estimativa provida pela odometria com a observação da localização de uma base. Para o planejamento e execução de rotas, utilizou-se o algoritmo A* combinado com o comportamento "Go to Goal". Também discutem-se possíveis melhorias para a implementação desenvolvida, utilizando técnicas de aprendizado por reforço. O filtro de Kalman provou-se uma técnica eficiente para computar a localização do robô, especialmente quando mais de uma base é utilizada. As técnicas utilizadas para implementação do módulo de planejamento de caminhos também atingiram êxito.

Palavras-chave – V-REP Pioneer Localização KF EKF A* A-Star GoToGoal Aprendizado por reforço

I. INTRODUÇÃO

O desenvolvimento de um robô jardineiro envolve uma grande quantidade de desafios, entre eles: a movimentação do robô com base em seu modelo cinemático, a percepção de sua localização, a identificação da saúde das plantas através de uma câmera, a identificação do tipo de planta tratada, o planejamento do percurso do robô (para visitar as plantas periodicamente), a atuação sobre as plantas (para a adição de adubo ou água, por exemplo) e a interface com o usuário, permitindo a flexibilização de diversos recursos.

Neste projeto, isolamos duas questões essenciais para um robô desse tipo. O planejamento da rota, necessário para atingir todas as plantas, e o desenvolvimento da implementação de um modelo de localização altamente preciso. Para possibilitar a implementação dessas duas provas de conceito, certas premissas foram assumidas, desacoplando-as de um cenário maior e mais complexo. Tais premissas serão discutidas e apresentadas ao longo do artigo.

Todas as simulações expostas foram realizadas no simulador V-REP utilizando o Pioneer 3-DX. As implementações foram feitas utilizando Java 8 e Python 3.5. O módulo de localização encontra-se em <https://github.com/luwood/MO810-vrep-python>, já o módulo relacionado ao planejamento de caminhos pode ser acessado em <https://github.com/karreiro/pathfinding-lab>, por fim, o projeto final integrando os dois módulos com o V-REP encontra-se em <https://github.com/mateuscoradini/final-project>.

Nas seções subsequentes, abordaremos respectivamente: II) Localização, onde Luísa discute as técnicas e os resultados obtidos utilizando odometria, uma base para fusão sensorial e os conceitos que envolvem a implementação do filtro de Kalman;

III) Planejamento e execução de rotas, onde Guilherme expõe os desafios envolvendo a implementação do algoritmo A* em um cenário envolvendo um robô móvel; em IV) Q-Learning e Aprendizado, Mateus apresenta técnicas para evoluirmos a solução apresentada utilizando aprendizado para coordenação dos comportamentos; e finalmente em V) todos integrantes concluem interpolando todos os tópicos abordados.

II. LOCALIZAÇÃO

A. Odometria

O cálculo da odometria é realizado com base na estimativa de velocidade das rodas. Cada roda possui um *encoder* que provê sua posição angular. Através da coleta temporal desta informação é possível determinar sua velocidade utilizando a seguinte fórmula:

$$V = \frac{\Delta\theta}{\Delta time} R$$

Em que $\Delta\theta$ representa a diferença angular entre posições do *encoder* durante um intervalo de tempo $\Delta time$ e R é o raio da roda. É importante destacar que o cálculo da diferença angular deve levar em conta a orientação do giro e o universo em que os ângulos estão.

Dada a velocidade de cada roda, pode-se calcular a velocidade linear e angular do robô através da fórmula:

$$V = \frac{V_r + V_l}{2}$$
$$\omega = \frac{V_r - V_l}{D}$$

Em que V_r é a velocidade da roda direita, V_l é a roda esquerda, D é a distância entre as rodas, V é a velocidade linear e ω é a velocidade angular.

A pose do robô no momento t depende da pose anterior, em $t - 1$, e pode ser calculada através das equações:

$$x_t = x_{t-1} + (\Delta s * \cos(\theta_{t-1} + \frac{\Delta\theta}{2}))$$
$$y_t = y_{t-1} + (\Delta s * \sin(\theta_{t-1} + \frac{\Delta\theta}{2}))$$
$$\theta = \theta_{t-1} + \Delta\theta$$

A implementação do cálculo da odometria é feita pela classe *OdometryPoseUpdater*. Para fins práticos a pose inicial do robô é obtida com a leitura do *Ground Truth*. O cálculo da velocidade da roda encontra-se em uma classes distinta

chamada *Wheel*. A orientação do giro é obtida utilizando a hipótese que a diferença angular deve ser sempre menor do que π .

B. Localizando a Base

A ideia inicial deste projeto era permitir que a localização do robô fosse obtida a partir da comunicação com uma base. O princípio seria semelhante a tecnologia utilizada no StarGazer (HagiSonic): o robô envia um sinal e a base o reflete. Deste modo é possível determinar a distância entre os dois objetos.

1) *Teoria*: Através da distância de um único ponto, é impossível determinar sua localização precisa. Considerando o sistema local de coordenadas do robô, pode-se ver na figura 1 que a base poderia estar em qualquer ponto do círculo determinado pela distância calculada entre o sensor e a base. Portanto, são necessários mais sensores no robô para determinar a localização da base.

Com três sensores é possível determinar a posição da base através da resolução de um sistema linear de equações. Na figura 2 podemos ver que o círculo que parte de cada sensor, se intersecta em um único ponto.

A equação de cada uma das circunferências pode ser descrita da seguinte forma:

$$r_1^2 = (x - x_1)^2 + (y - y_1)^2 \quad (1)$$

$$r_2^2 = (x - x_2)^2 + (y - y_2)^2 \quad (2)$$

$$r_3^2 = (x - x_3)^2 + (y - y_3)^2 \quad (3)$$

Para encontrar o ponto de intersecção entre as três circunferências, é necessário encontrar os valores de x e y combinando as três equações quadráticas em um sistema de duas equações lineares. Subtraindo (2) de (1) e (3) de (1):

$$2x(x_2 - x_1)^2 + 2y(y_2 - y_1)^2 + (x_1^2 - x_2^2) + (y_1^2 - y_2^2) - (r_1^2 - r_2^2) = 0$$

$$2x(x_3 - x_1)^2 + 2y(y_3 - y_1)^2 + (x_1^2 - x_3^2) + (y_1^2 - y_3^2) - (r_1^2 - r_3^2) = 0$$

A solução do sistema é a localização da base considerando o sistema de coordenadas local do robô.

2) *Transformação de coordenadas*: Para implementação do filtro de Kalman utilizado neste trabalho é necessário identificar a posição da base no sistema de coordenadas globais. A transformação do sistema de coordenadas locais do robô para o sistema global é dado pela rotação (4) seguida da translação (5) do ponto (x, y) , no qual dx , dy e α são dados pela pose do robô.

$$\begin{bmatrix} \cos(\alpha) & -\sin(\alpha) & 0 \\ \sin(\alpha) & \cos(\alpha) & 0 \\ 0 & 0 & 1 \end{bmatrix} \times \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (4)$$

$$\begin{bmatrix} 1 & 0 & dx \\ 0 & 1 & dy \\ 0 & 0 & 1 \end{bmatrix} \times \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (5)$$

3) *Implementação*: O robô possui três transceptores em seu topo que estão dispostos como mostrado na figura 2. A base se encontra nas coordenadas $(0, 0)$ do sistema global de referência. A distância entre os transceptores e a base é calculada utilizando o módulo de cálculo de distâncias provido pelo simulador V-REP. É importante ressaltar que este cálculo de distâncias em uma simulação mais verossímil precisaria ser implementado.

A implementação do cálculo de intersecção das três circunferências é o método *calculatePoint* no módulo *AngleUniverse*. Ele é utilizado pela classe *BaseDetector* para calcular a posição da base dadas as distâncias obtidas dos transceptores. A base é representada pela classe *DetectedBase* que possui o método *getAbsolutePosition* que realiza a transformação das coordenadas locais para as coordenadas globais dada uma determinada pose.




Figura 1. Robô com apenas um sensor de distância da base

C. Filtro de Kalman

O filtro de Kalman (KF) é uma implementação de filtros *Bayesianos* que realiza remoção de ruídos e predição de valores num sistema de estados contínuos. O interessante desta técnica é sua capacidade de combinar diferentes estimativas e suas respectivas covariâncias, computando uma distribuição Gaussiana baseada apenas em estados anteriores.

Por definição, o KF trabalha com probabilidades lineares. Sua versão estendida (EFK) trabalha com a hipótese de as funções que modelam as probabilidades não são lineares. Como um robô tipicamente pode realizar uma trajetória circular, o modelo mais indicado é o EKF.

A lógica do EKF está descrita pelo algoritmo 1, onde $\bar{\mu}_t$ pode ser entendido como a estimativa do estado no tempo t ,




Figura 2. Robô três sensores de distância da base

Algorithm 1 Extended Kalman filter $\bar{\mu}_t, \mu_{t-1}, \Sigma_{t-1}, \Sigma_{\Delta t}, z_t$

```

 $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + R_t$ 
 $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1}$ 
 $\mu_t = \bar{\mu}_t + K_t (z_t - \hat{z}_t)$ 
 $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$ 
return  $\mu_t, \Sigma_t$ 

```

μ_{t-1} o cálculo do estado no tempo $t-1$, Σ_{t-1} a covariância calculada em $t-1$ e z_t são as observações no tempo t .

1) *Localização com EKF*: Esta sessão é dedicada a explicar como o filtro de Kalman Extendido pode ser utilizado para realizar a localização do robô com o auxílio da detecção de *landmarks*. As fórmulas utilizadas foram primariamente retiradas da tabela 7.2 do livro *Probabilistic Robotics*[1]. Como suporte também foi utilizada uma apresentação realizada em 2014[2].

O objetivo da utilização do filtro é a melhoria na cálculo da pose do robô. Portanto, na primeira linha do algoritmo 1, μ_t representa a pose do robô no instante de tempo t . A estimativa de μ_t , $\bar{\mu}_t$, é dada pelo computação da odometria.

A primeira linha do algoritmo pode ser entendida como o modelo de erro da odometria. Portanto, foi acrescentado mais um fator em sua composição. Sua forma final é dada pela equação:

$$\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + V_t \Sigma_{\Delta t} V_t^T + R_t$$

Os valores de G_t , $\Sigma_{\Delta t}$, V_t e R_t estão descritos abaixo:

$$\beta_t = \theta_{t-1} + \frac{\Delta \theta_t}{2}$$

$$G_t = \begin{bmatrix} 1 & 0 & -\Delta s * \sin(\beta_t) \\ 0 & 1 & \Delta s * \cos(\beta_t) \\ 0 & 0 & 1 \end{bmatrix}$$

$$\Sigma_{\Delta t} = \begin{bmatrix} K_s |\Delta s_t| & 0 \\ 0 & K_t |\Delta \theta_t| \end{bmatrix}$$

$$D = \text{wheelsDistance}$$

$$V_t = \begin{bmatrix} \frac{1}{2} \cos(\beta_t) - \frac{\Delta s}{2D} \sin(\beta_t) & \frac{1}{2} \cos(\beta_t) + \frac{\Delta s}{2D} \sin(\beta_t) \\ \frac{1}{2} \sin(\beta_t) + \frac{\Delta s}{2D} \cos(\beta_t) & \frac{1}{2} \sin(\beta_t) - \frac{\Delta s}{2D} \cos(\beta_t) \\ \frac{1}{D} & \frac{1}{D} \end{bmatrix}$$

$$R_t = \begin{bmatrix} \sigma_x^2 & 0 & 0 \\ 0 & \sigma_y^2 & 0 \\ 0 & 0 & \sigma_\theta^2 \end{bmatrix}$$

A segunda linha do algoritmo calcula a matriz K_t , conhecida como o ganho de Kalman. Essa matriz pode ser entendida como o mecanismo que indica se deve-se confiar no valor estimado (odometria) ou na observação dos sensores (z). No cenário proposto, os sensores são capazes de estimar a posição de *landmarks* cuja posição real é conhecida anteriormente. A matriz Q representa a distribuição dos erros das observações. A matriz H_t é a matriz Jacobiana do cálculo de z . Portanto, para cada *landmark* que encontra-se em (L_x, L_y) , as matrizes H e Q recebem duas linhas:

$$x_t = \bar{\mu}_t[x], y_t = \bar{\mu}_t[y]$$

$$q = (L_x - x_t)^2 + (L_y - y_t)^2$$

$$H_t = \begin{bmatrix} -\frac{L_x - x_t}{\sqrt{q}} & -\frac{L_y - y_t}{\sqrt{q}} & 0 \\ \frac{L_y - y_t}{q} & -\frac{L_x - x_t}{q} & -1 \end{bmatrix}$$

$$Q_t = \begin{bmatrix} \sigma_{Id}^2 & 0 \\ 0 & \sigma_{l\theta}^2 \end{bmatrix}$$

A terceira linha do algoritmo realiza o cálculo de μ_t . A equação $z_t - \hat{z}_t$ calcula um valor chamado de *inovação* ou resíduo. Em termos práticos ela apenas estima a diferença entre onde o *landmark* deveria estar e onde ele está. A formulação utilizada na implementação realiza na verdade a diferença inversa $\hat{z}_t - z_t$ e matriz H_t foi apresentada de acordo com essa mudança. Para cada *landmark* utilizado duas linhas são acrescentadas as matrizes:

$$z = \begin{bmatrix} L_{range} \\ L_{bearing} \end{bmatrix}$$

$$\bar{z} = \begin{bmatrix} l_{range} \\ l_{bearing} \end{bmatrix}$$

Onde L representa a posição real do *landmark* e l a posição calculada através dos sensores. As funções de distância e inclinação podem ser calculadas através das equações:

$$p_{range} = \sqrt{(p_x - x_t)^2 + (p_y - y_t)^2}$$

$$p_{bearing} = \arctan2((p_y - y_t), (p_x - x_t)) - \theta_t$$

2) *Implementação*: A implementação do filtro estendido de Kalman encontra-se na classe *KalmanFilterPoseUpdater*. É importante notar que este componente utiliza o cálculo da odometria e sempre realiza a atualização do último valor calculado pela mesma.

Os valores das constantes utilizadas estão descritos na tabela I

Tabela I
CONSTANTES UTILIZADAS

Variável	Valor
K_s	0.1
K_t	0.1
σ_x	1
σ_y	1
σ_θ	1
σ_{Id}	0.5
$\sigma_{I\theta}$	0.1

D. Resultados

Os experimentos realizados com as técnicas de estimativa de pose do robô utilizam o algoritmo de Braitenberg para movimentação do mesmo.

1) *Odometria*: O gráfico comparando a posição real do robô e a posição calculada através da odometria pode ser visto na figura 3. É possível observar que o trajeto em linha reta obtido pela odometria é preciso. Porém assim que a primeira curva é realizada a diferença entre as posições começa a divergir. A diferença torna-se maior a cada iteração devido aos erros acumulados. A tabela II mostra a evolução do erro no cálculo da orientação durante um determinado período de teste.

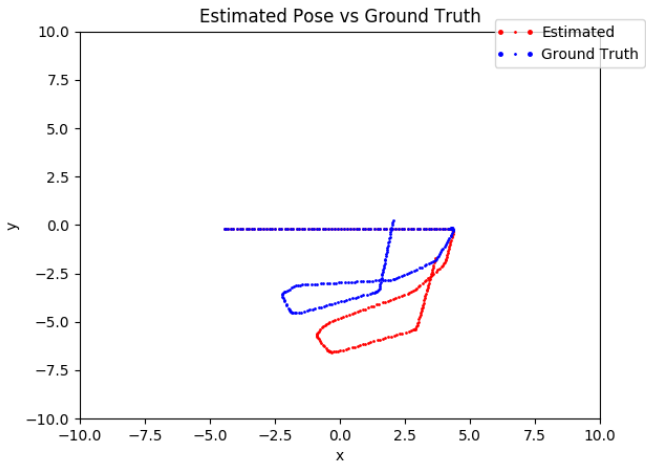


Figura 3. Odometria

Pode-se concluir que a odometria é um método de estimativa extremamente suscetível a erros acumulados. Para tornar este

Tabela II
DIFERENÇA θ EM GRAUS - A CADA 200MS

Real	Odometria	Erro
-0.424	-0.406	0.018
-0.515	-0.488	0.027
-0.783	-0.718	0.065
-1.182	-1.065	0.117
-2.033	-1.818	0.215
-3.048	-2.724	0.324
-4.355	-3.861	0.494
-6.122	-5.416	0.706
-7.843	-6.953	0.89
-9.851	-8.747	1.104
-12.613	-11.227	1.386
-14.864	-13.288	1.576
-18.003	-16.129	1.874
-22.479	-20.084	2.395

método viável seria necessário realizar correções no cálculo da orientação. A utilização de uma bússola, por exemplo, poderia auxiliar nesta computação.

2) *Filtro de Kalman Estendido*: A figura 4 mostra a comparação entre a posição estimada pela odometria e o filtro de Kalman e a posição real do robô quando apenas uma base é utilizada. Pode-se observar a evidente melhoria no trajeto calculado em comparação com a figura 3 (cenário que utiliza apenas a odometria). Porém também fica evidente que em alguns pontos o erro na predição da rota é maior do que em outros.




Figura 4. EKF: Utilizando 1 base

Na tentativa de melhorar o cálculo da trajetória, foi acrescentada mais uma base, na posição (3, -3). O resultado desta iteração pode ser visto na figura 5. A rota torna-se mais precisa do que quando utiliza-se apenas uma base.

Acrescentando mais uma base no ambiente, na coordenada (4, 6), o cálculo da trajetória fica muito próximo da trajetória




Figura 5. EKF: Utilizando 2 bases

real, como pode ser notado na figura 6.




Figura 6. EKF: Utilizando 3 bases

III. PLANEJAMENTO E EXECUÇÃO DE ROTAS

O conceito de planejamento de caminhos é bastante amplo em robótica, englobando desde tópicos relacionados a inteligência artificial até teoria de controle. Entretanto, em suma, tal conceito refere-se técnicas para mover um robô de determinando ponto a outro [3].

O módulo de planejamento de rota funciona considerando a premissa da existência de um grid com informações do ambiente. Tal discretização deve conter coordenadas de paredes, obstáculos, plantas e qualquer outro entrave que influencie na rota do robô. Dessa maneira, o robô pode ser capaz de visitar todas as plantas, desviando de eventuais obstáculos.

Com esta premissa bem definida, note que este módulo possui dois grandes desafios, analisados nas próximas sub-

seções: planejar rotas e seguir determinada trajetória, até o objetivo definido.

A. Planejamento de rota

Para realizar o planejamento dos caminhos, chegou-se a conclusão que o algoritmo A* (ou A-Star, ou ainda, A-Estrela) seria o mais apropriado para a realização de tal tarefa, pois é uma das melhores estratégias para planejamento de rotas que pode ser aplicado em um grid métrico. Combinando conceitos do algoritmo do melhor caminho com heurística, o A-Star possui ótimos resultados [3], num tempo bastante razoável, considerando o escopo do problema abordado.

A base do A* é sua função de avaliação de nó, que calcula a relevância de cada nó no grid, considerando sua origem e o destino na trajetória. Tal função pode ser representada da seguinte maneira:

$$f(n) = g(n) + h(n)$$

O elemento "g(n)" representa o custo da locomoção do robô entre nó avaliado e o nó de origem, enquanto o "h(n)" representa o custo de locomoção do nó avaliado até o nó de destino. Repare que apesar de tal valor ser alcançável, uma heurística como Manhattan, distância Euclideana, ou ainda Chebyshev, apresenta-se muito mais eficiente e barata [3].

De modo genérico, podemos dizer que o comportamento do A* funciona basicamente da seguinte maneira:

- Primeiramente elenca o primeiro nó, e gradativamente se expande para os nós vizinhos;
- Cada vizinho sub-sequente é avaliado, caso não seja um obstáculo, pela função do A*, organizando os vizinhos de acordo com o valor obtido;
- Esse processo continua até que o nó destino seja atingido;
- Para que o caminho até o nó destino seja armazenado, é necessário um processo a parte [4].

Dessa maneira, é possível obter um caminho válido a partir de um grid com obstáculos, apenas possuindo um ponto de origem e um ponto de destino.

B. Execução de rota

Para permitir que o robô siga a rota, implementou-se um algoritmo "Go to Goal", que resumidamente, recebe uma coordenada qualquer, e auxilia o robô a chegar o mais perto possível de tal ponto.

Considerando o modelo cinemático do Pioneer, para que ele siga determinada coordenada, é necessário que seu ângulo se alinhe ao ângulo da coordenada desejada. Desta maneira, conforme o robô se desloca, alinha-se ao objetivo definido, conseguindo assim se aproximar cada vez mais da coordenada desejada.

Para realizarmos o alinhamento do ângulo do Pioneer com seu objetivo, utilizamos um controlador PID, acrônimo para "Proportional, Integral and Derivative". Os elementos que compõem a sigla descrevem os três elementos básicos de um controlador PID, que exercem funções específicas no sistema [5].

O componente "Proportional" auxilia o sistema evitando que reaja exageradamente a pequenos estímulos; já o componente "Integral" auxilia adicionando uma precisão a longo prazo com os erros acumulados ao longo do tempo; por fim, o componente "Derivative" auxilia em respostas rápidas a erros que aumentam repentinamente. Entretanto, se o erro for relativamente constante, este último componente pode ser zero [5]. Desta maneira, com o sinal de controle gerado pelo controlador PID, é possível ajustar a intensidade dos motores das rodas, alinhando o robô com o objetivo desejado.

C. Implementação

Com o algoritmo A* selecionado como melhor solução, ele foi primeiramente implementado em um módulo externo como prova de conceito. Em tal projeto, definiu-se além da implementação do algoritmo, a estrutura de persistência do grid e de outros detalhes relacionados ao planejamento de trajetórias.

O módulo planejador demonstrou possuir performance adequada ao contexto abordado, necessitado de apenas 170ms em média para planejar uma rota em um grid de 50 colunas, 50 linhas e diversos obstáculos. Sua complexidade é $O(E)$ onde "E" refere-se ao número de células no grid. Considerando que fizemos pouquíssimas otimizações e que nosso robô não exigia um tempo menor que esse, concluímos a implementação da PoC seria boa o suficiente para ser transferida ao projeto principal (veja a figura 7). Não utilizou-se diagonais no planejamento das rotas, a fim de facilitar comportamentos relacionados a eventuais colisões.




Figura 7. Prova de conceito do algoritmo A*

O próximo passo para integração foi traduzir o grid na cena do V-REP. Discretizou-se o cenário (conforme podemos ver na

figura 8) e criou-se um módulo que traduz as coordenadas das células para coordenadas no V-REP.




Figura 8. Cena discretizada em grid

Para seguir a trajetória definida, o robô basicamente recebe uma lista de coordenadas, representando o caminho a ser percorrido, e a desempilha nó a nó, até que o objetivo seja atingido. Dessa maneira, o robô consegue realizar a tarefa de visitar todas as plantas do cenário proposto.

A única especificidade adotada para atingir tal objetivo, refere-se a utilização de certas células alcunhadas de *padding*. Tais células são interpretadas pelo A-Star como obstáculos, porém na realidade demarcam regiões que não devem ser visitadas, pois submeteriam o robô a uma condição de risco, como por exemplo, passar perto demais de determinada quina. Com a lapidação do Go to Goal e de um grid mais preciso, este recurso certamente seria dispensável.

IV. Q-LEARNING E APRENDIZADO

Ao iniciar o modelo deliberativo de comportamento, traçamos como meta inicial abordar o aprendizado para chaveamento entre os comportamentos "Wall Follower" e "Avoid Obstacle", representados no código pelas classes SimpleWallFollower e SimpleAvoidObstacle.

Dessa maneira, iniciou-se o o processo de estudo que coordenaria os comportamentos de acordo com o algoritmo de aprendizado por reforço Q-Learning desenvolvido por Watkins [6]. Esta técnica é definida pelo próprio autor como "um processo de decisão Markov, ou cadeia controlada de Markov, que consiste em quatro partes: um estado-espço S, uma função A que possibilita ações para cada estado, uma função de transição T e uma função de recompensa R."

Considerando a equação segundo Geramifard, Walsh, Tellex e Chowdhary [7]:

$$Q(st, at) < -Q(st, at) + \alpha t [rt + 1 + \lambda \max Q(St+1, a) - Q(st, at)]$$

Onde: $Q(st, at)$ é o valor anterior, e αt é a taxa de aprendizado e como valor aprendido na expressão, $rt + 1$ é a recompensa observada após executar a ação at , λ é o fator de desconto e $\max Q(St+1, a)$ é a estimativa de ação futura, descontando-se o valor anterior.

Assim abordamos o modelo de aprendizado, mapeando os possíveis estados, como definido na figura 9. Onde 1 representara o estado inicial parado, 2 o comportamento de wall-follower, 3 o avoid-obstacle e 4 uma situação de risco.




Figura 9.

O modelo não se mostrou efetivo para o comportamento esperado de exploração. Verificou-se que era necessário mais que um estado ação de simples coordenação de comportamento. Entretanto uma implementação para entender os passos do algoritmo encontra-se no projeto.

O algoritmo traduzido para linguagem estruturada, seria segundo Lima Júnior [8]:

- Para cada ciclo do estado de treino

- Selecione um estado randomico inicial.
- Enquanto (o estado final não chegar), faça:
 - Selecione uma possivel ação, considerando o proximo estado.
 - Recupere o valor maximo de Q(recompensa) para o valor considerado proximo estado.
 - Compute valor da recompensa: $Q(\text{estado}, \text{ação}) = Q(\text{estado}, \text{ação}) + \alpha * (R(\text{estado}, \text{ação}) + \gamma * \text{Max}(\text{proximo estado}, \text{todas ações}) - Q(\text{estado}, \text{ação}))$.
 - Coloque o valor de estado no estado corrente.

A matriz de recompensa a ações assim se fazia ineficiente para o resultado não mapeado que apresentamos como premissa, pois não recebia recompensas por exploração e sim por situações de risco e então alteraria para avoid-obstacle para ganhar recompensa exploratória e sempre continuava no mesmo estado, estando assim em um loop de estado ações pouco explorado.

As tentativas de implementação do algoritmo citado não foram finalizadas, considerando o modelo de recompensa de situação de risco e então começamos a pensar na integração das partes exploratórias de outros algoritmos e de um modelo futuro para exploração baseada no modelo de aprendizado e no algoritmo de Q-Learning. Este modelo deve criar um conjunto de ações com melhor recompensa definida por exploração de localização, como por exemplo, usar o mapeamento do ambiente e odometria para distinguir os objetos localizados e assim denominar o labirinto e escolhas a fazer. Iniciamos a integração dessa classe com o objetivo de modelar o ambiente do grid como conhecemos, usando a classe PathPlanner, pois podíamos gerar um grid genérico, para então efetuar os cálculos para descobrir uma maneira de coordenar os comportamentos. Então iniciamos a modificação dos comportamentos para andar no grid de maneira coordenada, acima, abaixo, lateral esquerda, lateral direita, e verificar essas condições para validar se não havia obstáculos, que podem ser vista na classe QLearningBehavior, mas não foi finalizado a implementação e ficou como melhoria futura, baseada no conceito de mapeamento sensorial por objetivo e depois aplicar-se o aprendizado por reforço. Como demonstração, o algoritmo futuro, tende-se a partir de criar landmarks randomicos de posições livres encontradas, e então após comportamentos de coordenação simples, como andar para frente, lateral esquerda, lateral direita, e reverso, poderíamos determinar a exploração do ambiente e assim encontrar os objetivos exploratórios mais definidos, conforme imagem 10.

V. CONCLUSÃO

O filtro estendido de Kalman mostrou-se uma excelente maneira de realizar correções no calculo da odometria. A hipótese de estimar a pose do robô utilizando apenas uma base mostrou-se válida, porém exibe erros consideráveis que podem prejudicar os comportamentos do robô que dependem desta estimativa. Os experimentos deixaram claro que quanto mais landmarks são acrescentados, mais precisa fica a estimativa da pose.




Figura 10. Cena discretizada em grid

REFERÊNCIAS

- [1] S. Thrun, W. Burgard, and D. Fox, *Probabilistic robotics*. MIT press, 2005. 3
- [2] P. Pinheiro. (2014, May) Kalman filter for mobile robot localization @ONLINE. [Online]. Available: <https://docs.google.com/viewer?a=v&pid=sites&srcid=ZGVmYXVsdGRvbWFpbmV8Z3g6NWExMGI2MmZhZmViMzg3> 3
- [3] F. Duchoň, A. Babinec, M. Kajan, P. Beňo, M. Florek, T. Fico, and L. Jurišica, "Path planning with modified a star algorithm for a mobile robot," *Procedia Engineering*, vol. 96, pp. 59–69, 2014. 5
- [4] J. Yao, C. Lin, X. Xie, A. J. Wang, and C.-C. Hung, "Path planning for virtual human motion using improved a* star algorithm," in *Information Technology: New Generations (ITNG), 2010 Seventh International Conference on*. IEEE, 2010, pp. 1154–1158. 5
- [5] T. Wescott, "Pid without a phd," *Embedded Systems Programming*, vol. 13, no. 11, pp. 1–7, 2000. 5, 6
- [6] C. J. C. H. Watkins, "Learning from delayed rewards," Ph.D. dissertation, King's College, Cambridge, 1989. 6
- [7] A. Geramifard, T. J. Walsh, S. Tellex, G. Chowdhary, N. Roy, J. P. How *et al.*, "A tutorial on linear function approximators for dynamic programming and reinforcement learning," *Foundations and Trends® in Machine Learning*, vol. 6, no. 4, pp. 381–383, 2013. 6
- [8] F. C. d. Lima Júnior, "Algoritmo q-learning como estratégia de exploração e/ou exploração para metaheurísticas grasp e algoritmo genético," 2009. 7

O módulo de planejamento se mostrou bastante eficiente nesse cenário controlado. Entretanto, uma implementação com um grid com células ainda menores, com maior refinamento no momento de calcular o caminho, certamente garantiria que o robô pudesse acessar pontos específicos do cenário com maior precisão. O módulo de planejamentos poderia contar com outros comportamentos, ativados de acordo com faixas de coordenadas para garantir uma navegação mais dinâmica. Além disso, o Go to Goal também pode ser ainda mais refinado.

A integração do processo de localização com o módulo de planejamento se deu através de serviços Python consumidos por um cliente Java. Dessa maneira conseguimos garantir bastante desacoplamento entre as implementações, utilizando o melhor de cada tecnologia durante o desenvolvimento desta prova de conceito..

O processo de reforço por aprendizado necessita ser revisto e necessita de uma implementação mais ampla do que abordagem de simples coordenação de lógica fuzzy existente para situações de risco. Vimos que a necessidade de navegação e sistema de recompensa pode ser utilizado determinando um grid de objetivo, nesse grid, que pode ser mapeado por pequenos intervalos de tempos, o robô pode explorar pequenos objetivos simples, até conseguir completar a matriz do ambiente com demarcações de landmarks e riscos. Após esse processo o robô pode se basear na matriz de escolhas das melhores ações de recompensa pelo processo de aprendizado por reforço.